



Analisis Komparatif Kinerja Algoritma Support Vector Machine, Random Forest, dan Naive Bayes untuk Klasifikasi Sentimen pada Komentar YouTube

(Center, Bold, Times New Roman 15, Maksimum antara 10-14 kata, Huruf Awal Huruf Besar)

Author¹, Author¹, Eustachius Dito Dewantoro^{2*}

(Center, Times New Roman 10, First name Middle name Last name)

¹Fakultas Ilmu Komputer, Teknik Informatika, Universitas Dian Nuswantoro, Semarang, Indonesia

(Center, Times New Roman 9, ¹Jika penulis di institusi yang sama)

²Fakultas, Program Studi, Nama Institusi, Kota, Indonesia

Email: ¹Author1@email.com, ^{2,*}Author2@email.com

Email Penulis Korespondensi: emailpenuliskorespondensi@email.com

Submitted: 99/99/9999; Accepted: 99/99/9999; Published: 99/99/9999

(Justify, Bold, Times New Roman 9, Before 6 Pt)

Abstrak— Perkembangan media sosial seperti YouTube telah menjadikannya platform utama bagi masyarakat untuk menyuarakan opini terhadap isu sosial-politik, salah satunya adalah peristiwa "demo 25 agustus". Volume data komentar yang masif menyulitkan analisis opini publik secara manual, sehingga diperlukan pendekatan komputasi seperti analisis sentimen. Penelitian ini bertujuan untuk mengklasifikasikan sentimen publik ke dalam dua kategori (positif dan negatif) serta membandingkan kinerja dari tiga algoritma machine learning: Naive Bayes, Random Forest, dan Support Vector Machine (SVM) untuk menemukan model klasifikasi yang paling efektif. Metode penelitian dimulai dari pengumpulan 2917 data komentar, diikuti oleh tahap pra-pemrosesan teks, pelabelan sentimen otomatis berbasis leksikon, dan pembobotan fitur menggunakan TF-IDF. Hasil penelitian menunjukkan bahwa sentimen negatif mendominasi opini publik sebesar 78.8%. Dalam evaluasi model, Support Vector Machine (SVM) menunjukkan performa terbaik dengan mencapai tingkat akurasi sebesar 88,2%, mengungguli Random Forest dengan akurasi 83,1% dan Naive Bayes sebesar 81,2%. Hasil ini mengindikasikan bahwa SVM merupakan model yang paling akurat untuk studi kasus klasifikasi sentimen pada komentar YouTube berbahasa Indonesia.

Kata Kunci: Analisis Sentimen; Komentar YouTube; Naive Bayes; Random Forest; Support Vector Machine (SVM); TF-IDF
(Terurut, paling sedikit 5 kata yang berhubungan dengan isi penelitian dipisahkan dengan titik koma, After 6 pt, Before 6 pt)

Abstract— The development of social media such as YouTube has made it a primary platform for people to voice their opinions on socio-political issues, one of which is the "August 25 demo" event. The massive volume of comment data makes manual analysis of public opinion difficult, thus requiring a computational approach such as sentiment analysis. This research aims to classify public sentiment into two categories (positive and negative) as well as compare the performance of three machine learning algorithms: Naive Bayes, Random Forest, and Support Vector Machine (SVM) to find the most effective classification model. The research method begins with the collection of 2917 comment data, followed by a text preprocessing stage, automatic lexicon-based sentiment labeling, and feature weighting using TF-IDF. The research results show that negative sentiment dominates public opinion at 78.8%. In the model evaluation, Support Vector Machine (SVM) showed the best performance by achieving an accuracy rate of 88.2%, outperforming Random Forest with 83.1% accuracy and Naive Bayes at 81.2%. These results indicate that SVM is the most accurate model for the sentiment classification case study on Indonesian-language YouTube comments.

Keywords: Sentiment Analysis; YouTube Comments; Naive Bayes; Random Forest; Support Vector Machine (SVM); TF-IDF

1. PENDAHULUAN

(SUB JUDUL Center, Bold, Times New Roman 13, UPPER CASE, After 6 pt, Before 18 pt)

Era transformasi digital telah secara fundamental mengubah lanskap komunikasi publik, menjadikan media sosial sebagai arena utama wacana sosial dan politik. Platform seperti YouTube telah terbukti menjadi media yang signifikan untuk pemasaran politik dan diskusi publik di Indonesia, yang memungkinkan jutaan pengguna untuk mengekspresikan opini mereka [1]. Salah satu isu yang memicu diskusi publik secara masif adalah peristiwa "demo 25 agustus", yang menarik perhatian luas dan menghasilkan ribuan respons dalam bentuk komentar. Volume data tekstual yang sangat besar ini (*big data*) menghadirkan tantangan signifikan. Karakteristik komentar di media sosial sangat unik, seringkali menggunakan bahasa yang sangat informal, penuh dengan bahasa gaul, singkatan non-standar, dan ekspresi emosional yang kuat, yang memerlukan penanganan khusus dalam analisis teks [2]. Analisis manual terhadap ribuan komentar ini tidak hanya memakan waktu dan tenaga, tetapi juga sangat rentan terhadap bias subjektif. Kompleksitas ini diperparah oleh adanya fenomena disinformasi dan operasi pengaruh terkoordinasi, seperti aktivitas "buzzer" yang telah diidentifikasi dalam analisis komentar Instagram [3]. Aktivitas semacam ini dapat mendistorsi opini publik yang sebenarnya, sehingga membedakan antara sentimen organik dan yang dimanipulasi menjadi sangat sulit. Oleh karena itu, untuk mendapatkan wawasan yang objektif dan skalabel dari data yang bising (*noisy*) ini, diperlukan pendekatan komputasi otomatis yang canggih.

Solusi teknologis untuk tantangan ini terletak pada bidang *Natural Language Processing* (NLP) dan *machine learning*, khususnya melalui teknik yang dikenal sebagai analisis sentimen. Analisis sentimen bertujuan untuk mengklasifikasikan sentimen (misalnya positif atau negatif) dari teks secara otomatis, seringkali memanfaatkan



algoritma *machine learning* atau *deep learning* untuk menangani data bervolume besar [4]. Disiplin ilmu komputasi ini berfokus pada identifikasi, ekstraksi, dan kuantifikasi keadaan afektif atau opini subjektif yang diekspresikan dalam data teks. Dalam konteks penelitian ini, tujuannya adalah untuk mengklasifikasikan komentar publik ke dalam sentimen biner: Positif atau Negatif. Fokus biner ini sengaja dipilih untuk mempertajam pemahaman tentang polarisasi publik. Kemampuan untuk memetakan sentimen publik secara akurat sangat krusial. Bagi pembuat kebijakan dan lembaga pemerintah, ini berfungsi sebagai alat untuk memahami opini publik terhadap suatu isu atau peristiwa politik, seperti debat kandidat atau kebijakan yang sedang berjalan [5]. Bagi sosiolog dan ilmuwan politik, ini menyediakan data empiris untuk memahami dinamika sosial. Bagi media dan jurnalis, ini membantu mengukur dampak pemberitaan. Keberhasilan analisis sentimen ini sangat bergantung pada pemilihan model klasifikasi yang tepat, yang mampu menangani kompleksitas bahasa informal Indonesia.

Berbagai penelitian sebelumnya telah banyak menerapkan algoritma *machine learning* klasik untuk tugas klasifikasi teks dan analisis sentimen di media sosial Indonesia. Di platform Twitter, misalnya, algoritma Multinomial Naïve Bayes telah berhasil diterapkan untuk mendeteksi ujaran kebencian terhadap PSSI dengan performa klasifikasi yang kuat, mencapai F1-Score sebesar 91% [6]. Masih di platform yang sama, sebuah studi komparatif yang sangat relevan untuk analisis sentimen program PPPK secara langsung membandingkan Naïve Bayes dengan Support Vector Machine (SVM). Temuan kunci dari studi tersebut menunjukkan bahwa SVM secara signifikan lebih unggul, dengan perolehan akurasi 93,31% berbanding 89,24% untuk Naïve Bayes [7]. Platform Instagram juga telah menjadi objek penelitian populer, di mana SVM telah digunakan secara spesifik untuk menganalisis sentimen ujaran kebencian pada kolom komentar [8]. Kegunaan SVM pada Instagram juga diperkuat dalam konteks yang berbeda sebagai salah satu klasifikator kunci dalam mendeteksi akun palsu, di mana model tersebut mampu mencapai akurasi hingga 96,77% ketika dioptimalkan [9]. Selain itu, model berbasis pohon (*tree-based*) juga telah dieksplorasi; algoritma Decision Tree telah diimplementasikan untuk mengklasifikasikan ujaran kebencian di berbagai media sosial, yang menunjukkan potensinya sebagai dasar untuk metode *ensemble* yang lebih kompleks [10].

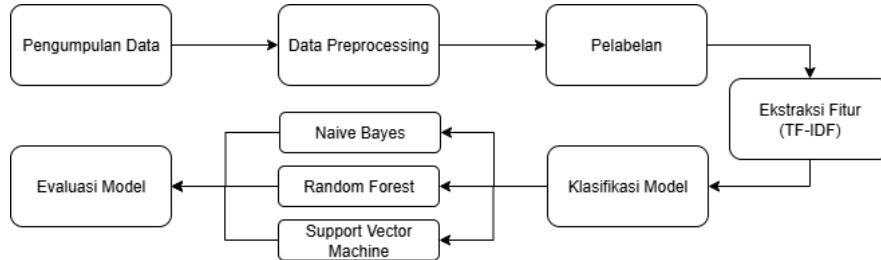
Berdasarkan tinjauan pustaka yang ekstensif tersebut, dapat diidentifikasi beberapa kesenjangan penelitian (*research gap*) yang signifikan. Kesenjangan pertama adalah fokus platform. Mayoritas literatur yang ada terkonsentrasi pada data dari Twitter (X) atau Instagram. Platform YouTube masih sangat kurang terwakili (*under-researched*) dalam konteks analisis sentimen berbahasa Indonesia. Padahal, karakteristik komentar YouTube secara unik berbeda: teksnya bisa jauh lebih panjang daripada *tweet* atau komentar IG, namun tetap mempertahankan tingkat informalitas yang tinggi, dan konteksnya sangat terikat pada konten audio-visual yang ditonton, yang dapat mempengaruhi pilihan kata dan ekspresi sentimen. Kesenjangan kedua adalah metodologi perbandingan. Banyak studi komparatif yang ada cenderung hanya membandingkan dua model (misalnya, Naïve Bayes vs SVM) atau berfokus pada implementasi satu model saja. Sementara itu, penelitian yang mulai mengeksplorasi *deep learning* seperti LSTM seringkali membutuhkan sumber daya komputasi yang besar [11]. Oleh karena itu, sebuah studi komparatif yang mengadu secara langsung tiga pilar algoritma *machine learning* klasik—Naive Bayes (sebagai *baseline* probabilistik), Random Forest (sebagai metode *ensemble* yang kuat), dan SVM (sebagai klasifikator *margin-based* berperforma tinggi)—pada *dataset* komentar YouTube berbahasa Indonesia yang sama masih jarang dilakukan dan sangat dibutuhkan.

Berdasarkan latar belakang dan *gap analysis* yang telah diuraikan, penelitian ini mengusulkan sebuah kerangka kerja untuk mengklasifikasikan sentimen publik pada isu "demo 25 agustus" dari komentar YouTube. Dengan fokus pada klasifikasi biner (positif dan negatif), penelitian ini bertujuan untuk secara sistematis menerapkan pipeline analisis sentimen dan mengevaluasi kinerja tiga model klasifikasi yang berbeda: Naive Bayes, Random Forest, dan SVM. Hasil dari perbandingan ini akan digunakan untuk menyimpulkan model mana yang paling akurat dan andal untuk studi kasus komentar YouTube, sehingga dapat memberikan kontribusi metodologis untuk penelitian di masa depan.

2. METODOLOGI PENELITIAN

2.1 Tahapan Penelitian (Subtitle Times New Roman 10, Left, After 6 pt)

Metodologi penelitian ini mengadopsi sebuah kerangka kerja (*framework*) penelitian yang sistematis dan telah divalidasi, yang umum diterapkan dalam studi analisis sentimen berbasis *machine learning*. Sebuah tinjauan literatur sistematis terhadap metode analisis sentimen mengonfirmasi bahwa alur kerja yang paling umum digunakan terdiri dari pengumpulan data, pra-pemrosesan, ekstraksi fitur, pemodelan, dan evaluasi [12]. Kerangka kerja ini, yang seringkali membandingkan berbagai algoritma untuk menemukan yang paling optimal, telah terbukti efektif dalam berbagai penelitian untuk mengolah data teks mentah menjadi wawasan yang terstruktur [13].

**Gambar 1.** Tahapan Penelitian

Secara spesifik, alur kerja yang diimplementasikan dalam penelitian ini diilustrasikan pada Gambar 1. Tahapan diawali dengan Pengumpulan Data mentah dari YouTube API, diikuti oleh tahap Preprocessing yang komprehensif. Data bersih kemudian melalui proses Pelabelan sentimen otomatis. Teks berlabel ditransformasi menggunakan Ekstraksi Fitur TF-IDF. Penggunaan TF-IDF sebagai metode pembobotan kata yang dilanjutkan dengan klasifikasi *machine learning* juga merupakan pendekatan yang telah terbukti efektif dalam studi sejenis [7], [10]. Dataset yang siap pakai ini kemudian dibagi menjadi data latih dan data uji untuk tahap Klasifikasi, di mana tiga model (Naive Bayes, Random Forest, dan SVM) dilatih. Model-model yang telah dilatih kemudian diuji performanya pada tahap Evaluasi. Terakhir, hasil akurasi dari ketiga model tersebut Dibandingkan untuk mengidentifikasi model yang paling unggul. Detail dari setiap tahapan ini akan dijelaskan pada sub-bab berikutnya.

2.2 Pengumpulan Data (After 6 pt, Before 6 pt)

Tahap pengumpulan data merupakan langkah awal dalam penelitian ini, di mana data primer berupa komentar publik diekstraksi dari platform YouTube. Proses akuisisi data dilakukan secara otomatis (*crawling*) dengan memanfaatkan YouTube Data API v3. Penggunaan Antarmuka Pemrograman Aplikasi (API) untuk mengumpulkan dataset komentar YouTube merupakan metode yang lazim dan tervalidasi dalam berbagai penelitian analisis sentimen [14]. Dengan menggunakan API tersebut dan kata kunci pencarian spesifik yaitu "demo 25 agustus", berhasil dikumpulkan dataset mentah sebanyak 2.917 komentar. Dataset ini kemudian disimpan dalam format file .csv untuk diproses pada tahap selanjutnya.

2.3 Data Preprocessing

Data komentar mentah yang diperoleh dari YouTube pada dasarnya bersifat tidak terstruktur dan mengandung banyak *noise* (derau). Oleh karena itu, tahap pra-pemrosesan data sangat krusial untuk membersihkan dan mentransformasi data teks ini menjadi format yang bersih dan terstruktur. Penelitian sebelumnya telah membuktikan secara empiris bahwa penerapan tahapan *preprocessing* yang komprehensif memiliki dampak yang signifikan terhadap performa dan akurasi model klasifikasi sentimen [15]. Proses ini meliputi *Cleaning* (menghapus URL/simbol), *Case Folding* (penyeragaman huruf kecil), Normalisasi (pembakuan kata), *Stopword Removal* (penghapusan kata henti), dan *Stemming* (pencarian kata dasar).

2.4 Pelabelan Data

Setelah data teks bersih, setiap komentar diberi label sentimen untuk dapat digunakan dalam pelatihan model klasifikasi. Proses pelabelan dilakukan secara otomatis dengan pendekatan berbasis leksikon (*lexicon-based*), yang merupakan metode analisis sentimen yang umum digunakan dengan memanfaatkan fitur leksiko-semantik dari sebuah kamus [16]. Secara spesifik, penelitian ini menggunakan InSet Lexicon, sebuah kamus sentimen berbahasa Indonesia yang telah terbukti efektif ketika diimplementasikan dalam penelitian analisis sentimen baru-baru ini [17]. Proses pelabelan bekerja dengan menghitung skor sentimen total untuk setiap komentar berdasarkan kata-kata di dalamnya. Sesuai fokus penelitian pada klasifikasi biner, komentar dengan total skor > 0 diberi label Positif dan komentar dengan total skor <= 0 diberi label Negatif.

2.5 Ekstraksi Fitur (TF-IDF)

Model *machine learning* tidak dapat memproses data teks mentah secara langsung, sehingga data yang telah melalui tahap pra-pemrosesan perlu ditransformasi menjadi representasi vektor numerik. Penelitian ini menggunakan metode Term Frequency-Inverse Document Frequency (TF-IDF) untuk ekstraksi fitur dan pembobotan kata. TF-IDF adalah sebuah teknik statistik yang mengubah teks menjadi representasi numerik dengan menilai frekuensi sebuah kata dalam dokumen dan pentingnya kata tersebut dalam seluruh koleksi teks [5]. Metode ini bekerja dengan memberikan bobot tinggi pada kata-kata yang sering muncul dalam satu komentar tetapi jarang muncul di komentar-komentar lainnya, sehingga menjadikannya fitur pembeda yang kuat. Penggunaan TF-IDF sebagai metode pembobotan telah terbukti memberikan hasil akurasi yang baik ketika dikombinasikan dengan model klasifikasi seperti SVM untuk analisis sentimen berbahasa Indonesia [18].

2.6 Klasifikasi Model



Pada tahap ini, dataset yang telah berbentuk vektor TF-IDF dibagi menjadi dua subset data yang independen: 80% data latih (*training data*) dan 20% data uji (*testing data*). Pembagian ini penting untuk memastikan bahwa evaluasi model dilakukan pada data yang belum pernah dilihat oleh model selama proses pelatihan. Data latih digunakan untuk "mengajari" model mengenali pola sentimen positif dan negatif berdasarkan fitur TF-IDF, sedangkan data uji digunakan untuk mengukur seberapa baik model dapat menggeneralisasi pengetahuannya pada data baru. Penelitian ini secara spesifik membandingkan kinerja dari tiga algoritma klasifikasi yang berbeda, yaitu Naive Bayes, Random Forest, dan Support Vector Machine (SVM), yang masing-masing dijelaskan di bawah ini.

2.6.1 Naive Bayes

Naive Bayes adalah salah satu algoritma klasifikasi probabilistik yang populer dan sering digunakan sebagai model baseline dalam tugas klasifikasi teks karena kesederhanaan dan efisiensinya [19]. Algoritma ini didasarkan pada Teorema Bayes, yang secara matematis mendeskripsikan probabilitas suatu kejadian berdasarkan pengetahuan sebelumnya tentang kondisi yang mungkin terkait dengan kejadian tersebut. Algoritma ini disebut "naif" karena mengasumsikan independensi antar fitur (kata), yang memungkinkan penyederhanaan perhitungan likelihood menjadi perkalian probabilitas setiap kata muncul di kelas tersebut [20]. Meskipun asumsi ini seringkali tidak sepenuhnya akurat untuk data teks, Naive Bayes dikenal efisien secara komputasi dan telah terbukti efektif dalam analisis sentimen opini publik berbahasa Indonesia [21]. Klasifikasi dilakukan dengan memilih kelas C yang menghasilkan nilai probabilitas posterior $P(C|x)$ tertinggi. Variasi Multinomial Naive Bayes sering digunakan untuk klasifikasi teks karena cocok untuk data dengan frekuensi kata [20].

$$P(C|x) = \frac{P(x|C)P(C)}{P(x)} \quad (1)$$

Dalam rumus tersebut, $P(C|x)$ merupakan probabilitas posterior, yaitu probabilitas kelas C (misalnya, Positif atau Negatif) terjadi setelah melihat data komentar x . $P(x|C)$ adalah probabilitas likelihood, yaitu probabilitas data komentar x muncul jika diketahui kelasnya adalah C . $P(C)$ adalah probabilitas prior, yaitu probabilitas awal bahwa suatu komentar termasuk dalam kelas C . Terakhir, $P(x)$ adalah probabilitas evidence, yaitu probabilitas data komentar x muncul secara keseluruhan; nilai ini sering diabaikan dalam klasifikasi karena konstan untuk semua kelas [19]. Dengan asumsi independensi Naive Bayes, $P(x|C)$ disederhanakan menjadi $\prod_{i=1}^n P(x_i|C)$ [19], [20].

2.6.2 Random Forest

Random Forest adalah algoritma *ensemble learning* yang efektif untuk klasifikasi, yang bekerja dengan membangun banyak Decision Tree (pohon keputusan) [19], [20]. Prediksi dari semua pohon ini kemudian digabungkan untuk menghasilkan keputusan akhir yang lebih akurat dan stabil, mengandalkan "kebijaksanaan kolektif" yang lebih baik daripada satu pohon tunggal [19], [20]. Metode ini telah terbukti efektif untuk analisis sentimen berbahasa Indonesia (Ardiansyah et al., 2023). Untuk mencegah *overfitting* dan menjaga keragaman antar pohon, Random Forest menggunakan dua teknik utama: Bagging (melatih pohon pada subset data acak) dan Random Feature Selection (memilih fitur acak pada tiap *node* pemisah) [19], [20]. Setelah sejumlah N pohon (T_1, T_2, \dots, T_N) dibangun, proses klasifikasi untuk data baru x dilakukan dengan *majority voting*. Prediksi akhir dari Random Forest, $C_{RF}(x)$, adalah kelas yang paling sering diprediksi oleh mayoritas pohon [20].

$$C_{RF}(x) = mode\{C_1(x), C_2(x), \dots, C_N(x)\} \quad (2)$$

Dalam rumus tersebut, $C_{RF}(x)$ adalah prediksi kelas akhir dari Random Forest untuk input data x , sedangkan $C_i(x)$ adalah prediksi kelas dari pohon ke- i (dari total N pohon). Fungsi *mode* {....} memilih kelas yang paling banyak muncul (majoritas) dari semua prediksi pohon individual. Penggunaan Decision Tree sebagai dasar dari Random Forest relevan dalam konteks klasifikasi teks ujaran kebencian [22].

2.6.3 Support Vector Machine (SVM)

Support Vector Machine (SVM) adalah algoritma *supervised learning* yang efektif untuk data berdimensi tinggi seperti teks TF-IDF [19], [20]. SVM bekerja dengan menemukan *hyperplane* (batas keputusan) optimal yang memaksimalkan *margin*—yaitu, jarak ke titik data terdekat (*support vectors*) dari setiap kelas [19]. Maksimasi *margin* ini bertujuan meningkatkan kemampuan generalisasi model pada data baru [20]. Untuk menangani data yang tidak dapat dipisahkan secara linier, SVM dapat menggunakan *kernel trick* (seperti kernel RBF) [19], [20]. SVM telah terbukti memberikan akurasi tinggi untuk analisis sentimen pada data media sosial Indonesia, dan penelitian menunjukkan performanya seringkali kompetitif atau mengungguli Naive [23]. Proses pelatihan SVM melibatkan penyelesaian masalah optimasi kuadratik untuk menemukan parameter *hyperplane* (W dan b) yang memaksimalkan *margin* [19].

$$\min_{w,b} \frac{1}{2} \|W\|^2 \quad (3)$$

Dengan Kendala (subject to): $y_i(W \cdot X_i + b) \geq 1$, untuk semua $i = 1, \dots, N$



Tujuannya adalah meminimalkan $\frac{1}{2} \|W\|^2$ (yang ekuivalen dengan memaksimalkan *margin* $2/\|W\|$). Kendala $y_i(W \cdot X_i + b) \geq 1$ memastikan setiap titik data X_i dengan label y_i (misal, +1 atau -1) berada di sisi *margin* yang benar [20]. Titik-titik data di mana kendala ini terpenuhi secara tepat (nilainya = 1) adalah *support vectors* yang menentukan posisi akhir *hyperplane* [19].

2.7 Evaluasi Model

Kinerja dari model klasifikasi (Naive Bayes, Random Forest, dan SVM) dievaluasi untuk mengukur performa dan kemampuan generalisasinya. Proses ini menggunakan *hold-out validation*, di mana data uji (*test set*) sebesar 20% dari total dataset digunakan untuk pengujian. Pengukuran kinerja didasarkan pada empat metrik standar yang diturunkan dari *confusion matrix*, yaitu Akurasi, Presisi, Recall, dan F1-Score [24]. Hasil dari metrik-metrik ini akan dibandingkan secara komprehensif untuk mengidentifikasi model dengan kinerja paling optimal, dengan F1-Score menjadi metrik penting untuk menangani potensi ketidakseimbangan kelas data [25].

$$\text{Akurasi} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}} \quad (4)$$

$$\text{Presisi} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (5)$$

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (6)$$

$$\text{F1-Score} = 2 \times \frac{\text{Presisi} \times \text{Recall}}{\text{Presisi} + \text{Recall}} \quad (7)$$

Penjelasan untuk komponen rumus di atas adalah sebagai berikut: TP (*True Positive*) adalah data positif yang diprediksi benar, TN (*True Negative*) adalah data negatif yang diprediksi benar, FP (*False Positive*) adalah data negatif yang salah diprediksi positif, dan FN (*False Negative*) adalah data positif yang salah diprediksi negatif [24]. Akurasi mengukur proporsi total prediksi yang benar. Presisi mengukur ketepatan prediksi positif, sementara Recall mengukur kemampuan model mengidentifikasi kasus positif aktual. F1-Score adalah rata-rata harmonik dari Presisi dan Recall, yang ideal untuk dataset yang tidak seimbang [25].

3. HASIL DAN PEMBAHASAN

Pada bagian ini berisi hasil dan pembahasan dari topik penelitian, yang bisa dibuat terlebih penerapan metode yang digunakan, baik secara sederhana dengan mengemukakan data yang ada pada penelitian. Bagian ini juga merepresentasikan penjelasan yang berupa penjelasan, gambar, tabel dan lainnya. Banyaknya kata pada bagian ini berkisar **min 1800 kata**.

3.1 Subtitle 1

- a. Gunakan huruf kecil dan abjad untuk penomoran list.
- b. Setting 5 mm untuk bagian kiri menjorok kedalam.
- c. Jika lebih dari 1 level penomoran gunakan penomoran angka untuk list selanjutnya:
 - 1. Gunakan penomoran angka.
 - 2. Selanjutnya

3.1.1 Subtitle 2

(Untuk list penomoran gunakan a, b, c dan selanjutnya)

3.2 Implementasi/Pengujian (bila ada)

Berisi hasil implementasi aplikasi ataupun hasil program (yang penting saja), ataupun hasil dari pengujian metode.

3.3 Pembahasan

Berisi hasil pembahasan dan bisa perbandingan dari hasil penelitian sebelumnya.

4. KESIMPULAN

Bagian ini berisi kesimpulan yang menjawab hal segala permasalahan yang terdapat didalam penelitian. Pada kesimpulan dapat dikemukakan keterbatasan penelitian sehingga dapat dilakukan perbaikan pada penelitian selanjutnya. Isi kesimpulan tidak berupa point-point, namun berupa paragraph. Banyaknya kata pada bagian ini berkisar **min 200 kata**.

REFERENCES (After 6 pt, Before 6 pt)

(Times New Roman, 9)



Semua pengutipan referensi yang dikutip di artikel ini **WAJIB TERDAPAT PADA ISI ARTIKEL** dan **WAJIB** untuk menggunakan **alat referensi seperti MENDELEY/ENDNOTE dengan format IEEE**, 80% literatur **PRIMER** (jurnal, prosiding, laporan penelitian, paten, standar, dokumen sejarah, buku hasil riset dengan keterbaruan 5 tahun) dan 20% literatur **SEKUNDER** (buku **minimal 2 buku**, website yang dapat dipercaya) dalam kurun waktu sekurang-kurangnya 10 tahun terakhir

Jumlah referensi yang digunakan **minimum sebanyak 20 Referensi**.

(Hapus semua informasi berwarna merah/abu-abu tambahan seperti ini di naskah pengiriman Anda)